

In [1]:

```
import scipy.stats as stats
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import pylab
from numpy import ndarray
%matplotlib inline
```

In [2]:

```
# Считываем данные из файла.
data = pd.read_csv('Weibull.csv')
print(data[:5], len(data))
```

```
      1.4
0  0.00
1  0.00
2  3.42
3  0.00
4  0.18 3651
```

In [3]:


```
# Функция заменяющая нули на 0.0001.
def null_changer(x):
    if x == 0.:
        return 0.0001
    else:
        return x
```

In [4]:

```
# Как видим, одно из значений съехало в название столбца.(1.4)
# Считаем данные в np.array.
# Заменяем нули на 0.0001.
X = list(map(null_changer, data[data.columns[0]]))
X.insert(0, 1.4)
X = np.array(X)
```


In [44]:

```
# Посмотрим на наши данные.
plt.figure(figsize=(10, 3))
plt.scatter(X, np.zeros(len(X)), alpha = 0.25, color = "g", label = "Our sample from Cauchy.csv")
plt.xlim([-10, 1000])
plt.show()
```



In [45]:

```
# И посмотрим на десятичные логарифмы наших данных.
plt.figure(figsize=(10, 3))
plt.scatter(np.log10(X), np.zeros(len(X)), alpha = 0.05, color = "g", label = "Our sample from Cauchy.csv")
plt.xlim([-3, 3])
plt.show()
```



По графику выборки данных видно, что больше всего точек, находятся у 0, а по графику логарифмов мало что понятно.

К задаче.

В полночь работники банка измеряют две величины: X^1 — максимальное значение баланса за день, X^2 — значение баланса в полночь. Считается, что величина $X = X^1 - X^2$ имеет распределение Вейбулла с функцией распределения $1 - e^{(-x)^\gamma} I(x \geq 0)$, где $\gamma > 0$ - параметр формы.

Плотность этого распределения $\gamma x^{\gamma-1} e^{-x^\gamma} I(x \geq 0)$,

а ее логарифм $\ln \gamma + (\gamma - 1) \ln x - x^\gamma, x \geq 0$

Оценим параметр формы методом максимального правдоподобия, оценку произведем по сетке в логарифмической шкале, зная что $\log_{10} \gamma \in [-2, 2]$, шаг 10^{-3} .

In [5]:

```
# Функция логарифма правдоподобия.
# При параметре a = 1, плотность распределения в scipy.stats.exponweib совпадает с нашей.
def loglike(gamma, X):
    return stats.exponweib.logpdf(X, a = 1., c=gamma).sum()
```

In [6]:

```
# Функция подсчета при каком параметре гамма правдоподобие максимально.
# Принимает на вход логарифмическую шкалу.
def fit(log_space, X):
    like_array = [loglike(np.power(10, i), X) for i in log_space]
    optimal_gamma = log_space[np.argmax(like_array)]
    return optimal_gamma, np.power(10, optimal_gamma)
```

In [7]:

```
# Сетка в логарифмической шкале.
grid = np.linspace(-2., 2., num = 4. / 0.001)
```

а) Оценим параметр формы по первым четырем годам.

In [8]:

```
result_half = fit(grid, X[: (365 * 4)])
```

In [9]:

```
print(result_half)
(-0.8087021755438859, 0.15534519495338567)
```

б) Оценим параметр формы по всей выборке.

In [10]:

```
result_all = fit(grid, X)
```

In [11]:

```
print(result_all)
(-0.80270067516879218, 0.15750680602705364)
```

In [12]:

```
print(result_all[0] - result_half[0], result_all[1] - result_half[1])
0.00600150037509 0.00216161107367
```

Вывод: Оценки γ методом максимального правдоподобия за 4 года и за 10 лет равны соответственно $\gamma = 0.1553$, $\log_{10}(\gamma) = -0.8087$, $\gamma = 0.1575$, $\log_{10}(\gamma) = -0.8027$ различаются на 6 тысячных в логарифмической шкале, и на около 2 тысячных в реальной. Значит 4х лет вполне достаточно для оценки.